Del ML clásico al Deep Learning: clasificación de ecografías mamarias con redes neuronales y Streamlit

ACA N° 2 · Aprendizaje Automático · Especialización en Inteligencia Artificial · CUN – Escuela de Ingeniería · Docente: Hamilton Rivera Flor
Integrantes: Kevin David Guzman Payares · Leider Antonio Pacheco Quinto · Joaquin Pablo Redondo Tapias · Jose Luis Ruiz Ospino

App: https://aca2-ecografia-mamaria-dl-26xgtzbp9fp9bjsii42gxm.streamlit.app/
Video: *(enlace del video – por publicar)*
Código: https://github.com/leiderpq5521-creator/ACA2-Ecografia-Mamaria-DL

Objetivo general

Entrenar y ajustar redes neuronales profundas (CNN y Transformer) que clasifiquen ecografías mamarias en **normal, benigno o maligno**, priorizando la sensibilidad para la clase maligna, y desplegarlas en una app Streamlit con explicación visual (Grad-CAM).

Situación problema

¿Cómo aprovechar redes neuronales o modelos de Hugging Face para extraer patrones complejos en datos de salud y llevarlos a una interfaz interactiva?

En el ACA 1 la regresión logística clasificó tumores con 30 medidas *ya extraídas* (WDBC). Ahora la red aprende **directamente de la imagen** de ultrasonido, el primer examen clínico.

Dataset: BUSI (Al-Dhabyani et al., 2020)

- 780 ecografías de 600 mujeres (Hospital Baheya, El Cairo) con máscara de la lesión: 56 % benignas · 27 % malignas · 17 % normales.
- **Depuración:** 18 imágenes con la misma ecografía en dos clases y 38 duplicados excluidos → 724 útiles: train 507 · val 108 · test 109 (70/15/15, sin fuga).

Ruta metodológica

1 · Exploración y SQL
Inventario en **SQLite** (tamaño, intensidad, área de lesión, MD5, pHash). Consultas de balance y duplicados.

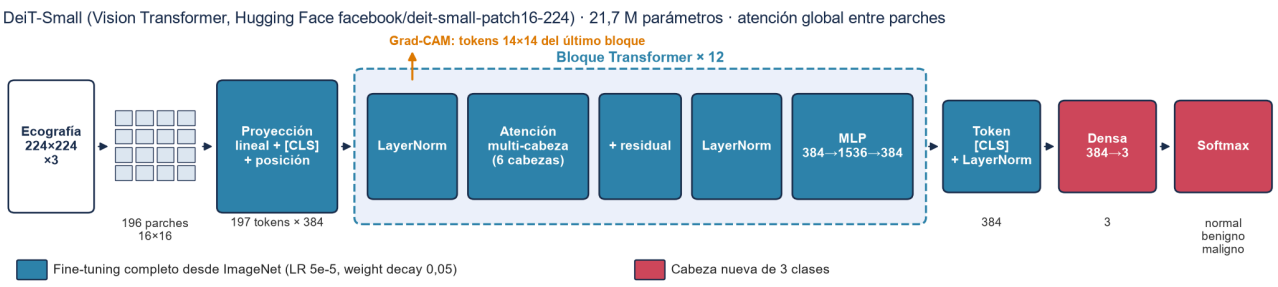
2 · Pipeline
pHash para conflictos y casi-duplicados; StratifiedGroupKFold; 224×224, normalización ImageNet; **aumento de datos** (recorte, volteo, rotación ±15°, brillo/contraste); pérdida ponderada.

3 · Modelado
CNN desde cero · **EfficientNet-B0** (*transfer learning* en 2 fases) · **DeiT-Small** (ViT, Hugging Face). AdamW, early stopping por F1 macro.

4 · Evaluación
Curvas loss/accuracy, F1 macro, recall maligno, matriz 3×3, ROC OvR, IC 95 % bootstrap, Grad-CAM vs. máscara.

5 · Despliegue
App Streamlit: imagen + Grad-CAM, lotes, historial y consultas SQL, desempeño.

Arquitectura seleccionada para la app (mejor F1 en validación): DeiT-Small, Vision Transformer de Hugging Face



La imagen se divide en 196 parches de 16×16 que se tratan como «palabras»; 12 bloques de autoatención relacionan todos los parches entre sí (contexto global de la lesión y su entorno). Preentrenado en ImageNet y ajustado por completo (LR 5e-5, weight decay 0,05). Superó a EfficientNet-B0 y a la CNN desde cero en validación.

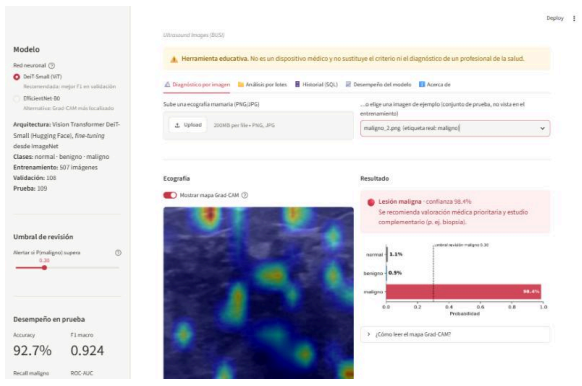
Resultados en prueba (n = 109, imágenes nunca vistas)

92,7 %	0,924	90,3 %	0,979
Accuracy	F1 macro	Recall maligno	ROC-AUC (OvR)

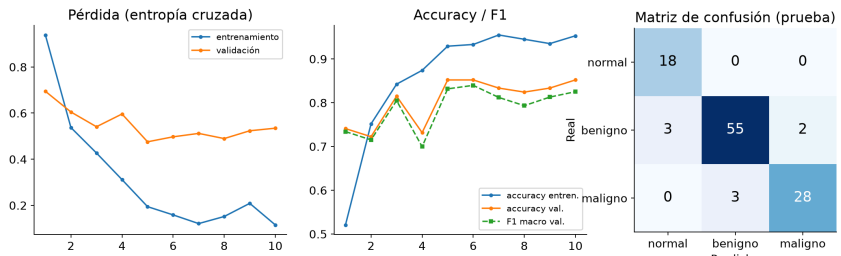
Modelo	Parám. (M)	Accuracy	F1 macro	ROC-AUC	Recall mal.
CNN desde cero	1,2	0,569	0,554	0,746	0,581
EfficientNet-B0	4,0	0,872	0,844	0,976	0,806
DeiT-Small (ViT)	**21,7**	**0,927**	**0,924**	**0,979**	**0,903**

IC 95 % (bootstrap) de DeiT-Small (ViT): accuracy 0,872–0,973 · F1 macro 0,869–0,971 · recall maligno 0,793–1,000. Por clase (F1): normal 0,923 · benigno 0,932 · maligno 0,918.

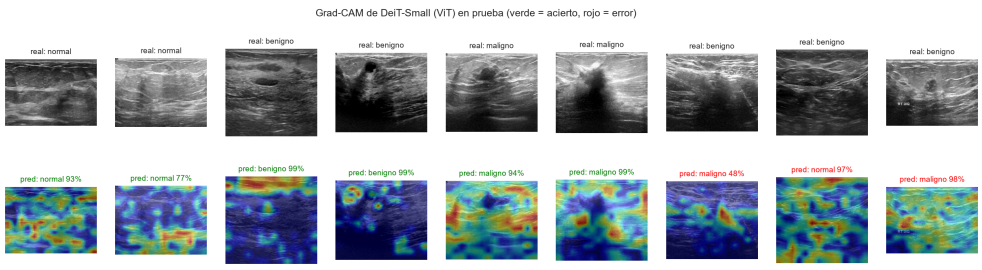
Vista previa de la app Streamlit



DeiT-Small (ViT): curvas de entrenamiento/validación y matriz de confusión



Interpretabilidad: Grad-CAM



En las 91 lesiones de prueba, la lesión ocupa en promedio 8,5 % de la imagen, pero concentra **2,8×** (EfficientNet-B0) y **1,8×** (DeiT-Small (ViT)) más energía del mapa de calor de lo esperado al azar. El ViT reparte su atención de forma más global; en la app se puede alternar con EfficientNet-B0 para ver un mapa más localizado.

Conclusiones

- **El transfer learning es decisivo con pocos datos:** con ~500 imágenes de entrenamiento, la CNN entrenada desde cero se queda en F1 macro 0,55, mientras que las redes preentrenadas en ImageNet llegan a 0,84 (EfficientNet-B0) y 0,92 (DeiT-Small).
- **El Vision Transformer fue el mejor modelo** (elegido por validación): en prueba alcanza accuracy 92,7 %, F1 macro 0,924 (IC 95 %: 0,87–0,97), ROC-AUC 0,979 y detecta 28 de 31 tumores malignos (recall 90,3 %).
- **La calidad de datos cambia el resultado:** se excluyeron 56 imágenes de BUSI (18 con la misma ecografía en dos clases) y se agruparon las casi idénticas para que ninguna quedara a la vez en entrenamiento y prueba; sin esto las métricas estarían infladas.
- **Las redes miran la lesión:** el mapa Grad-CAM concentra 2,8× (EfficientNet) y 1,8× (ViT) más energía dentro de la lesión de lo esperado al azar; la atención del Transformer es más global y la CNN, más localizada.
- **Puente con el ACA 1:** con 30 variables tabulares ya extraídas, una MLP y la regresión logística empatan (F1 0,988 vs. 0,976); el Deep Learning aporta su mayor valor cuando aprende directamente de la imagen.
- **Limitaciones:** un solo hospital, 109 imágenes de prueba y 3 tumores malignos no detectados: es una herramienta de apoyo educativo que requiere validación externa antes de cualquier uso clínico.

Referencias (APA 7)

Al-Dhabyani, W., Gomaa, M., Khaled, H., & Fahmy, A. (2020). Dataset of breast ultrasound images. *Data in Brief, 28*, 104863. https://doi.org/10.1016/j.dib.2019.104863

Selvaraju, R. R., Cogswell, M., Das, A., Vedantam, R., Parikh, D., & Batra, D. (2017). Grad-CAM: Visual explanations from deep networks via gradient-based localization. *Proceedings of the IEEE ICCV*, 618–626.

Tan, M., & Le, Q. (2019). EfficientNet: Rethinking model scaling for convolutional neural networks. *Proceedings of ICML*, 6105–6114.

Touvron, H., Cord, M., Douze, M., Massa, F., Sablayrolles, A., & Jégou, H. (2021). Training data-efficient image transformers & distillation through attention. *Proceedings of ICML*, 10347–10357.

Wolf, T., et al. (2020). Transformers: State-of-the-art natural language processing. *Proceedings of EMNLP: System Demonstrations*, 38–45.