Del ML clásico al Deep Learning: clasificación de ecografías mamarias con redes neuronales y Streamlit

ACA N° 2 · Aprendizaje Automático · Especialización en Inteligencia Artificial · CUN – Escuela de Ingeniería · Docente: Hamilton Rivera Flor
Integrantes: Kevin David Guzman Payares · Leider Antonio Pacheco Quinto · Joaquin Pablo Redondo Tapias · Jose Luis Ruiz Ospino

App: *(enlace de Streamlit Cloud – por publicar)*
Video: *(enlace del video – por publicar)*
Código: *(enlace del repositorio GitHub – por publicar)*

Objetivo general

Entrenar y ajustar redes neuronales profundas (CNN y Transformer) que clasifiquen ecografías mamarias en **normal, benigno o maligno**, priorizando la sensibilidad para la clase maligna, y desplegarlas en una app Streamlit con explicación visual (Grad-CAM).

Situación problema

¿Cómo aprovechar redes neuronales o modelos de Hugging Face para extraer patrones complejos en datos de salud y llevarlos a una interfaz interactiva?

En el ACA 1 la regresión logística clasificó tumores con 30 medidas *ya extraídas* (WDBC). Ahora la red aprende **directamente de la imagen** de ultrasonido, el primer examen clínico.

Dataset: BUSI (Al-Dhabyani et al., 2020)

- 780 ecografías de 600 mujeres (Hospital Baheya, El Cairo) con máscara de la lesión: 56 % benignas · 27 % malignas · 17 % normales.
- **Depuración:** 18 imágenes con la misma ecografía en dos clases y 38 duplicados excluidos → 724 útiles: train 507 · val 108 · test 109 (70/15/15, sin fuga).

Ruta metodológica

1 · Exploración y SQL
Inventario en **SQLite** (tamaño, intensidad, área de lesión, MD5, pHash). Consultas de balance y duplicados.

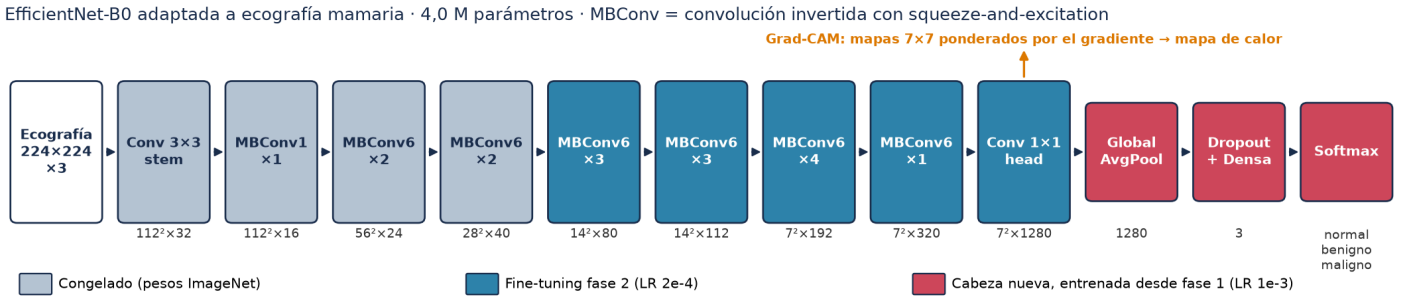
2 · Pipeline
pHash para conflictos y casi-duplicados; StratifiedGroupKFold; 224×224, normalización ImageNet; **aumento de datos** (recorte, volteo, rotación ±15°, brillo/contraste); pérdida ponderada.

3 · Modelado
CNN desde cero · **EfficientNet-B0** (*transfer learning* en 2 fases) · **DeiT-Small** (ViT, Hugging Face). AdamW, early stopping por F1 macro.

4 · Evaluación
Curvas loss/accuracy, F1 macro, recall maligno, matriz 3×3, ROC OvR, IC 95 % bootstrap, Grad-CAM vs. máscara.

5 · Despliegue
App Streamlit: imagen + Grad-CAM, lotes, historial y consultas SQL, desempeño.

Arquitectura seleccionada para la app: EfficientNet-B0 con *transfer learning*



Fase 1: sólo la cabeza nueva (backbone congelado). Fase 2: *fine-tuning* de los 4 últimos bloques MBConv + conv_head con LR 5× menor. Con ~500 imágenes, reutilizar filtros aprendidos en ImageNet evita el sobreajuste de una red entrenada desde cero; es ligera (16 MB, inferencia en CPU) y permite Grad-CAM.

Resultados en prueba (n = 109, imágenes nunca vistas)

61,5 %	0,613	58,1 %	0,784
Accuracy	F1 macro	Recall maligno	ROC-AUC (OvR)

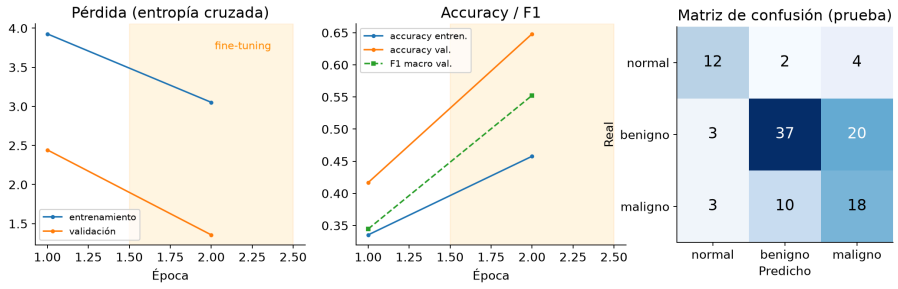
Modelo	Parám. (M)	Accuracy	F1 macro	ROC-AUC	Recall mal.
CNN desde cero	1,2	0,284	0,148	0,562	1,000
EfficientNet-B0	**4,0**	**0,615**	**0,613**	**0,784**	**0,581**
DeiT-Small (ViT)	21,7	0,661	0,550	0,888	0,129

IC 95 % (bootstrap) de EfficientNet-B0: accuracy 0,523–0,706 · F1 macro 0,507–0,705 · recall maligno 0,393–0,759. Por clase (F1): normal 0,667 · benigno 0,679 · maligno 0,493.

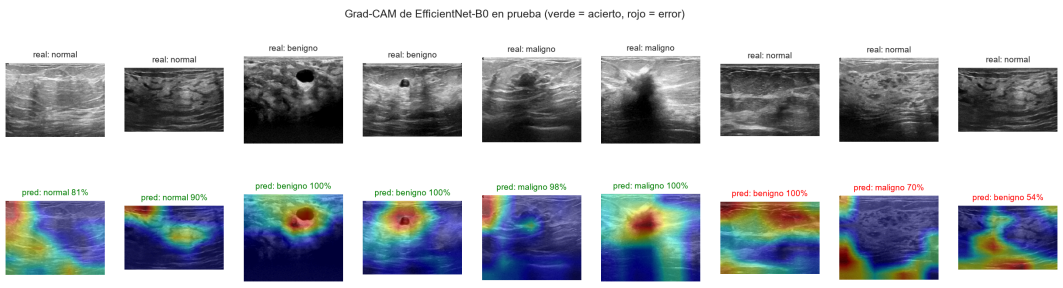
Vista previa de la app Streamlit

(captura pendiente)

EfficientNet-B0: curvas de entrenamiento/validación y matriz de confusión



Interpretabilidad: Grad-CAM



En las 91 lesiones de prueba, 10,8 % del mapa de calor cae dentro de la lesión segmentada, que ocupa en promedio 8,5 % de la imagen: **1,3×** lo esperado si la red mirara al azar.

Conclusiones

- Conclusión de prueba uno con texto suficientemente largo para ocupar una línea completa del póster.
- Conclusión dos de prueba con texto largo también para ver el espacio.
- Tres.
- Cuatro, más texto de relleno para ver el alto.

Referencias (APA 7)

Al-Dhabyani, W., Gomaa, M., Khaled, H., & Fahmy, A. (2020). Dataset of breast ultrasound images. *Data in Brief, 28*, 104863. https://doi.org/10.1016/j.dib.2019.104863

Selvaraju, R. R., Cogswell, M., Das, A., Vedantam, R., Parikh, D., & Batra, D. (2017). Grad-CAM: Visual explanations from deep networks via gradient-based localization. *Proceedings of the IEEE ICCV*, 618–626.

Tan, M., & Le, Q. (2019). EfficientNet: Rethinking model scaling for convolutional neural networks. *Proceedings of ICML*, 6105–6114.

Touvron, H., Cord, M., Douze, M., Massa, F., Sablayrolles, A., & Jégou, H. (2021). Training data-efficient image transformers & distillation through attention. *Proceedings of ICML*, 10347–10357.

Wolf, T., et al. (2020). Transformers: State-of-the-art natural language processing. *Proceedings of EMNLP: System Demonstrations*, 38–45.